

ĐỒ ÁN MÔN HỌC MÁY HỌC

PHÂN TÍCH CẢM XÚC ĐÁNH GIÁ CÔNG TY ITVIEC

Phân loại ba lớp từ review tiếng Việt bằng TF-IDF và mô hình học máy

GIẢNG VIÊN HƯỚNG DẪN

Thầy Cáp Phạm Đình Thắng

Khoa Khoa học Máy tính

SINH VIÊN THỰC HIỆN

Hoàng Hôn · Văn Duy · Duy Khang · Thành Trung

8.417 review nguồn | 8.414 review mô hình hóa | 3 lớp cảm xúc




Dữ liệu lệch mạnh và nhãn chỉ là nhãn yếu

POSITIVE : NEGATIVE

10,9 : 1

Nếu luôn đoán Positive, Accuracy đã gần 73,8%. Vì vậy, dự án chọn Macro F1 làm thước đo chính.



Ngôn ngữ pha trộn

Review dùng tiếng Việt, thuật ngữ IT, teencode và emoji.

Cảm xúc lẫn lộn

Một review thường khen môi trường nhưng chê lương, OT hoặc quản lý.

Nhãn suy ra từ rating

Rating 1–5 sao tạo nhãn weak label, không phải nhãn vàng do chuyên gia gán.

Pipeline từ dữ liệu nguồn đến ứng dụng

01

Dữ liệu

8.417 review
Title + Liked +
Improvement

02

Tiền xử lý

Unicode, emoji,
teencode
và tách từ

03

Đặc trưng

TF-IDF unigram +
bigram
5.000 chiều

04

Huấn luyện

5 mô hình
Stratified 5-fold CV

05

Ứng dụng

Đánh giá, insight
và Streamlit

Kết quả cuối

Logistic Regression + SMOTE

Final Test: Macro F1 0,5764

Web demo dự đoán theo thời gian thực

Làm sạch văn bản tiếng Việt theo hai tầng

Chuẩn hóa cơ bản

Unicode NFC, URL, email và chữ thường.

Chuẩn hóa tín hiệu

Emoji, emojicon, teencode và thuật ngữ IT.

Tách từ

Ưu tiên underthesea, dùng pyvi khi cần fallback.

Lọc từ dừng

Giữ từ phủ định và từ chỉ mức độ như “thấp”, “nhiều”.

REVIEW GÓC

Lương thấp, quản lý thiếu minh bạch và thường xuyên phải OT không lương.


SAU TIỀN XỬ LÝ

**lương thấp quản_lý thiếu minh_bạch
thường_xuyên ot không lương**

Ví dụ chạy trên pipeline và model bản sửa hiện tại.

Đầu ra `clean_basic_text` giữ cấu trúc tự nhiên. `clean_advance_text` phục vụ các mô hình ML.

Quản lý và lương liên hệ mạnh nhất với rating



MANAGEMENT VS RATING

0,7368

SALARY VS RATING

0,7343

OFFICE VS RATING

0,5423

Các điểm khía cạnh là tín hiệu dự báo rất mạnh nhưng không có ở đầu vào dự đoán review tự do. Dự án chỉ dùng chúng cho phân tích chẩn đoán.

Bigram cải thiện Macro F1 thêm 0,0153



5.000 đặc trưng

Giới hạn từ vựng để giữ ma trận gọn.

sublinear_tf = True

Giảm ảnh hưởng của từ lặp nhiều lần.

min_df = 2

Loại các token chỉ xuất hiện một lần.

8.414 review mô hình hóa

Development 6.731 | Final Test 1.683

Stratified split, seed 2026

Năm mô hình dùng cùng một contract TF-IDF


MNB	LR	SVM	RF	STK
Naive Bayes	Logistic Regression	Linear SVM	Random Forest	Stacking

SMOTE nằm bên trong từng fold huấn luyện



Validation fold không chứa mẫu tổng hợp, nhờ đó điểm CV không bị lạc quan giả tạo.

Xếp hạng gốc – Logistic Regression cải thiện sau sửa lỗi



KHOẢNG CÁCH TOP 2

0,0003

Model được triển khai

Bảng 5 model ban đầu
LR đạt 0,5727, hơn SVM 0,0003.

Sau sửa tiền xử lý
CV riêng tăng từ 0,5708 lên 0,5815.

Giữ đúng phạm vi so sánh
Chưa xếp hạng lại bốn model còn lại.

Bản sửa cải thiện nhẹ, nhưng lớp Negative vẫn khó

ACCURACY

74,33%

MACRO F1

0,5764


WEIGHTED F1

0,7540

SAI

432 / 1.683
(Bản cũ: 442 → Giảm 10 mẫu)

Thực tế / Dự đoán	Negative	Neutral	Positive
Negative	52 (45,6%)	41	21
Neutral	56	168 (51,2%)	104
Positive	44	166	1.031 (83,1%)



Đánh giá trên cùng tập Final Test chuẩn (1.683 mẫu) để bảo đảm tính đối chứng công bằng giữa hai phiên bản.

15 lỗi minh họa cho thấy ba dạng khó thường gặp

DỰ ĐOÁN SAI

432

25,7% của Final Test

15 lỗi đại diện được trích xuất minh họa cho 3 dạng khó phổ biến.

7 / 15

Review nhiều về ý

Một review vừa khen vừa chê, nên khó gói vào một nhãn duy nhất.

6 / 15

Phủ định hoặc cấu trúc khó

Từ phủ định và câu dài khiến tín hiệu TF-IDF khó diễn giải.


2 / 15

Nhãn hoặc tín hiệu chưa rõ

Rating và nội dung có thể lệch nhau; một số câu có ít từ model nhận ra.


Dạng lỗi do hệ thống phân loại sơ bộ theo từ khóa và cấu trúc câu.

Salary & benefits thấp nhất ở 4/5 công ty



Đây là phân tích mô tả của 5 công ty có nhiều review nhất, không phải bảng xếp hạng chất lượng doanh nghiệp.

TF-IDF cho biết độ nổi bật, không cho biết chiều tác động



NEGATIVE

99,0%

Cụm từ được giữ lại

“không lương” và “lương thấp”
là các đặc trưng riêng.

Giới hạn diễn giải

Trọng số TF-IDF cho biết độ nổi
bật. Muốn biết chiều tác động cần
xem thêm hệ số Logistic
Regression.

🗨️ **Review minh họa:** "Lương thấp, quản lý thiếu minh bạch và thường xuyên phải OT không lương." → Mô hình nhận diện: **Tiêu cực (99,0%)**

Bản sửa tốt hơn một chút, nhưng lớp Negative vẫn khó

Đã hoàn thành

- Pipeline text-only end-to-end
- Chọn model bằng 5-fold CV
- Đối chiếu lại Final Test cũ

Bài học

- Macro F1 quan trọng hơn Accuracy
- SMOTE phải nằm trong từng fold
- LR và SVM phù hợp dữ liệu thưa

Hạn chế

- Rating tạo weak label có nhiều
- Negative F1 chỉ đạt 0,3910
- TF-IDF chưa hiểu ngữ cảnh dài

CV Macro F1 0,5815; Final Test cũ 0,5764. Chênh 0,0052, chưa thấy lệch lớn.

Đóng góp của đề án và bước phát triển tiếp theo

Đóng góp

Pipeline ba lớp có thể tái lập

Từ dữ liệu, preprocessing, TF-IDF đến đánh giá.

Đánh giá đúng quy trình

Chọn bản sửa bằng CV; đối chiếu trên Final Test cũ.

Ứng dụng minh họa

Insight mô tả và dự đoán review theo thời gian thực.

Hướng phát triển

Gán nhãn thủ công

Tạo tập chuẩn nhỏ để đo mức nhiễu của weak label.

ABSA

Phân tích riêng lượng, OT, quản lý và môi trường.

Transformer tiếng Việt

Đối sánh với PhoBERT hoặc ViSoBERT khi có tài nguyên.

Live demo hệ thống phân tích cảm xúc

NGƯỜI TRÌNH BÀY

NGUYỄN DUY KHANG

Minh họa cách một review mới đi qua pipeline đã huấn luyện

01

Chọn review mẫu

Bấm mẫu “Nhiều vé” có sẵn trong ứng dụng

02

Quan sát dự đoán

Đọc nhãn cảm xúc và xác suất của ba lớp

03

Kiểm tra đầu vào

Xem văn bản sau tiền xử lý và các token TF-IDF nổi bật

Sau trang này, nhóm chuyển sang ứng dụng Streamlit để thao tác trực tiếp.